Предобработка данных с помощью Scikit-learn

Студент: Марван Шехата Зейтун
Дисциплина: Машинное обучение
Набор данных: Heart Failure Clinical Records (Kaggle)
Дата: 26 октября 2026 г.
Ссылка на код: https://github.com/MarwanShehata/Lab-1/

Аннотация

Основные средства предобработки scikit-learn были применены к шести непрерывным клиническим признакам 299 пациентов с сердечной недостаточностью. Стандартизация, масштабирование к диапазону, квантильное и степенное преобразования и квантильная дискретизация обучены, проверены по формулам и сопоставлены по гистограммам. Работа показывает, что линейные методы сохраняют форму распределения, нелинейные её меняют, а масштабировщик нужно обучать на тех данных, на которых он оценивается.

Цель и набор данных

Цель

Цель лабораторной работы — познакомиться с методами предобработки Scikit-learn: стандартизацией, масштабированием к диапазону, нелинейными преобразованиями и дискретизацией. Для каждого метода рассматривается его действие на данные, проверяются параметры и сравниваются полученные распределения.

Подготовка набора данных

Набор Heart Failure Clinical Records загружен из CSV. Бинарные признаки (anaemia, diabetes, high_blood_pressure, sex, smoking), переменная наблюдения time и целевая переменная DEATH_EVENT удалены, поскольку методы масштабирования имеют смысл только для непрерывных измерений.

В результате получена матрица из 299 наблюдений × 6 непрерывных признаков: age, creatinine_phosphokinase, ejection_fraction, platelets, serum_creatinine и serum_sodium. **[Вопрос 1, Задание 2]**

Рабочая матрица

Строки: 299 пациентов
Столбцы: 6 непрерывных признаков
Удалены: 5 бинарных, time, DEATH_EVENT
Ссылка на код: https://github.com/MarwanShehata/Lab-1/

Инструменты

Python
pandas
NumPy
Matplotlib
scikit-learn.preprocessing

Ход работы и затраченные усилия

Работа выполнялась в шесть этапов, каждый из которых опирался на массив, подготовленный на предыдущем.

1. Загрузить и отфильтровать данные, построить исходные гистограммы каждого признака.
2. Преобразовать датафрейм в массив NumPy типа float для трансформеров scikit-learn.
3. Обучить StandardScaler на первых 150 строках, затем на всех 299; проверить формулу вручную.
4. Применить MinMaxScaler, MaxAbsScaler, RobustScaler и собственную функцию масштабирования к [-5, 10].
5. Применить QuantileTransformer (равномерный и нормальный выход) и PowerTransformer.
6. Выполнить дискретизацию KBinsDiscretizer с отдельным числом интервалов для каждого признака.

Время и усилия

Значительная часть времени ушла на изучение темы, чтобы освежить понимание концепций предобработки, интерфейсов масштабировщиков и трансформеров scikit-learn, а также статистики: дисперсии, межквартильного размаха и квантилей. Мои предыдущие знания и опыт несколько отличались от рассматриваемого материала, поэтому такое повторение было необходимо, чтобы уверенно применять методы. Остальное время было посвящено реализации, отладке и оформлению результатов.

Исходные данные: диапазоны и типичные значения

Перед любыми преобразованиями я изучил исходные распределения и диапазоны признаков. В таблице 1 приведены минимум, максимум и медиана шести непрерывных признаков.

Признак	Мин.	Макс.	Медиана
age	40	95	60
creatinine_phosphokinase	23	7861	250
ejection_fraction	14	80	38
platelets	25100	850000	262000
serum_creatinine	0.5	9.4	1.1
serum_sodium	113	148	137

Таблица 1 Диапазоны и медианы признаков в исходных данных. **[Вопрос 1, Задание 4]**

creatinine_phosphokinase и serum_creatinine имеют сильную левостороннюю асимметрию с длинными хвостами, а serum_sodium — правостороннюю. Остальные признаки ближе к симметричным. **[Вопрос 1, Задание 4]**

Масштабы признаков различаются до пяти порядков, от serum_creatinine около 1 до platelets в сотнях тысяч, что и обосновывает необходимость масштабирования. **[Вопрос 1, Задание 4]**

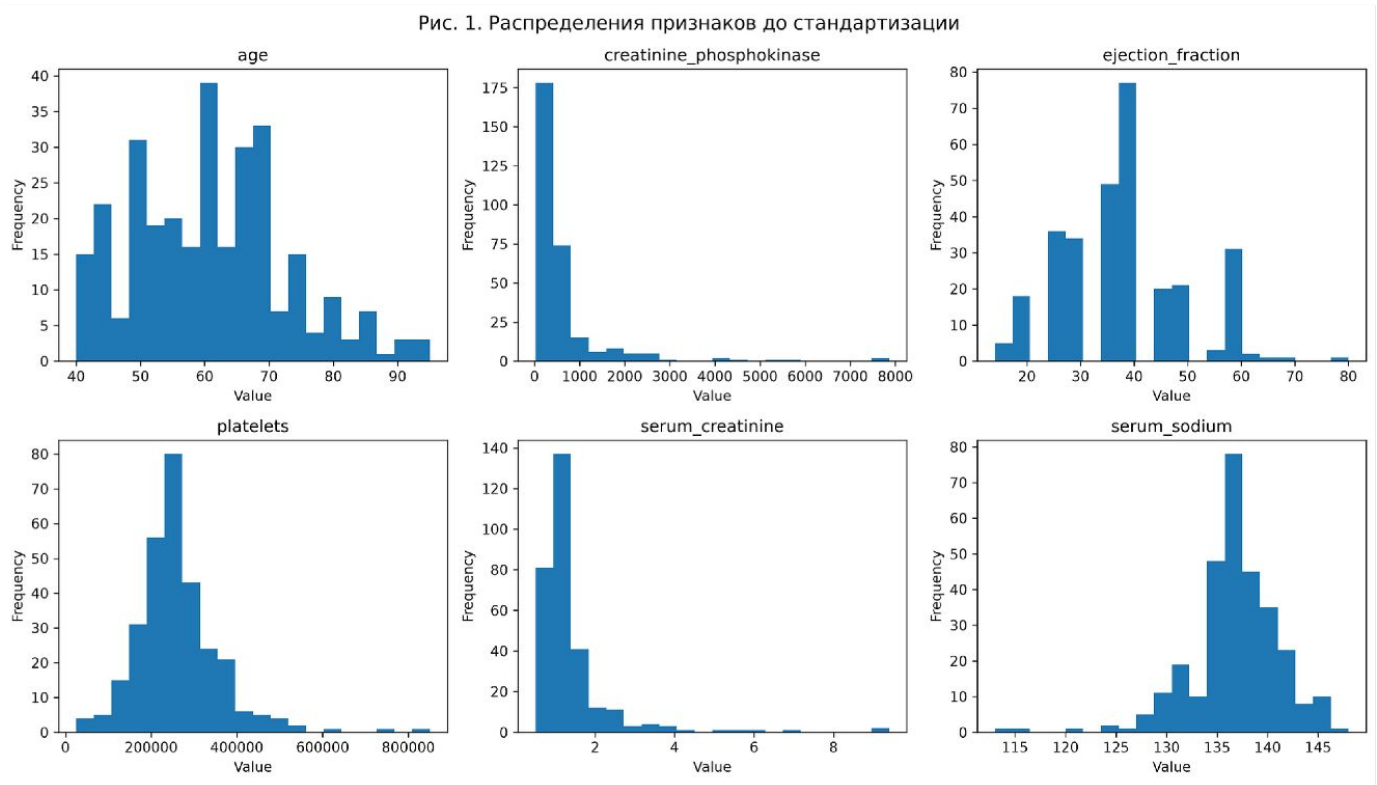


Рисунок 1. Распределения исходных данных до стандартизации. **[Вопрос 1, Задание 3]**

Стандартизация

Генеральная дисперсия: ddof = 0

$$z = \frac{x - \mu}{\sigma}, \qquad \sigma = \mathrm{var}^{1/2}$$

Обучение на первых 150 строках: μ = 62.95, 607.15, 37.95, 266746.75, 1.52, 136.45; σ = 12.45, 1189.74, 13.04, 96191.79, 1.17, 4.54. **[Вопрос 2, Задание 1]**

Формула для отдельного признака, например age: $z = (x - 62.95)/12.45$ **[Вопрос 2, Задание 5]**

- Ручной расчёт совпал с выходом масштабировщика (np.allclose = True); mean_ и var_ равны среднему и дисперсии NumPy по первым 150 строкам. **[Вопрос 2, Задание 6]**
- Обучение на всех 299: μ = 60.83, 581.84, 38.08, 263358.03, 1.39, 136.63; σ = 11.88, 968.66, 11.82, 97640.55, 1.03, 4.41. **[Вопрос 2, Задание 7]**

Наблюдение

Форма гистограмм не меняется; смещаются только положение и масштаб. **[Вопрос 2, Задание 4]**

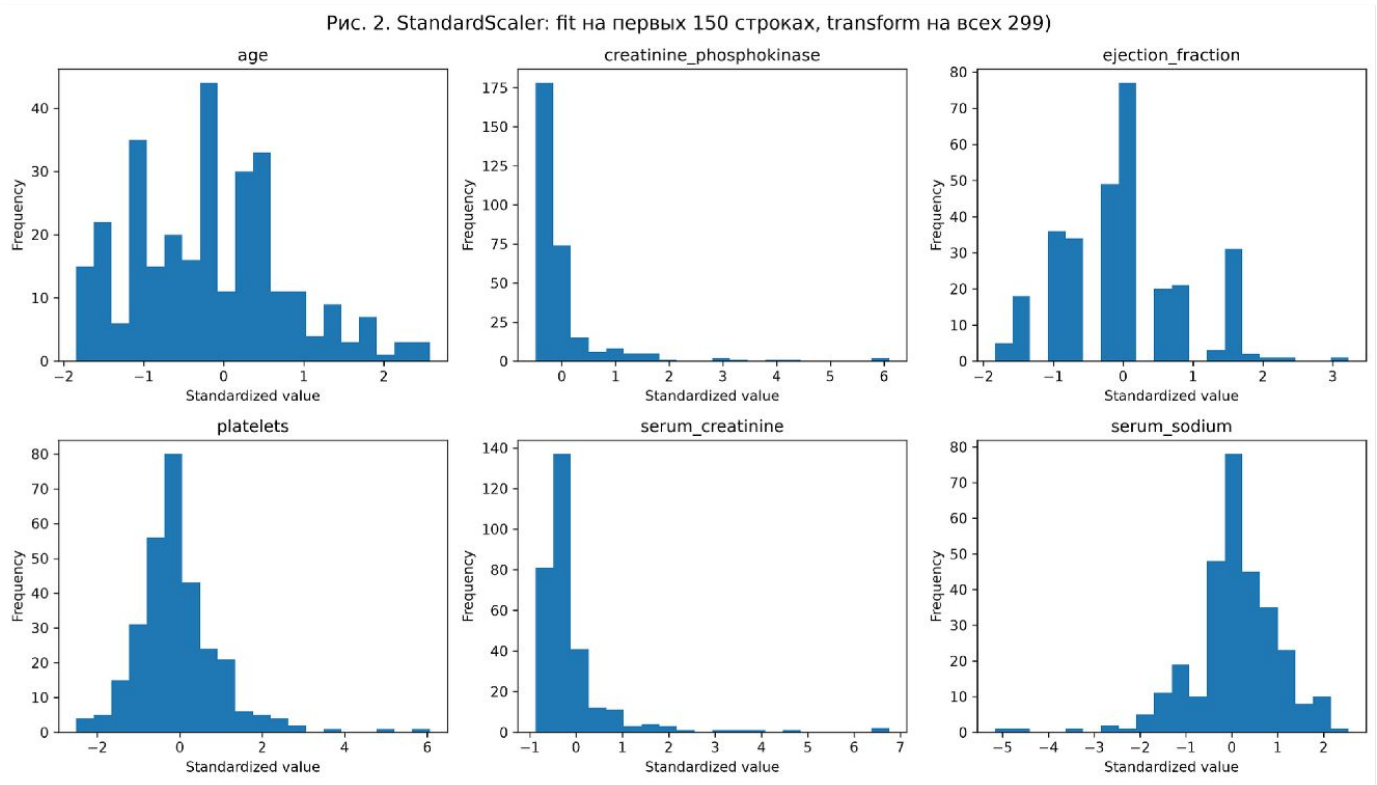


Рисунок 2. StandardScaler, обученный на первых 150 строках; преобразованы все 299 строк. **[Вопрос 2, Задание 3]**

Масштабирование к диапазону

Сравнивались четыре метода масштабирования к диапазону. Каждый из них — линейное отображение, заданное несколькими статистиками обучающих данных.

MinMax

$$x' = \frac{x - \min}{\max - \min}$$

MaxAbs

$$x' = \frac{x}{\max |x|}$$

Robust

$$x' = \frac{x - \text{median}}{\text{IQR}}$$

Собственная функция [-5, 10]

$$x' = -5 + 15 \cdot \frac{x - \min}{\max - \min}$$

- MinMax переводит данные в [0, 1]; data_min_ и data_max_ восстанавливают исходные минимум и максимум. **[Вопрос 3, Задание 3]**
- MaxAbs переводит данные в (0, 1], так как все значения положительны; max|x| равен исходным максимумам. **[Вопрос 3, Задание 4]**
- Robust центрирует по медианам 60, 250, 38, 262000, 1.1, 137 с IQR 19, 465.5, 15, 91000, 0.5, 6; диапазон не фиксирован, выбросы остаются далеко. **[Вопрос 3, Задание 4]**
- Собственная функция даёт точный минимум −5 и максимум 10 по каждому признаку и защищена от нулевого размаха. **[Вопрос 3, Задание 5]**

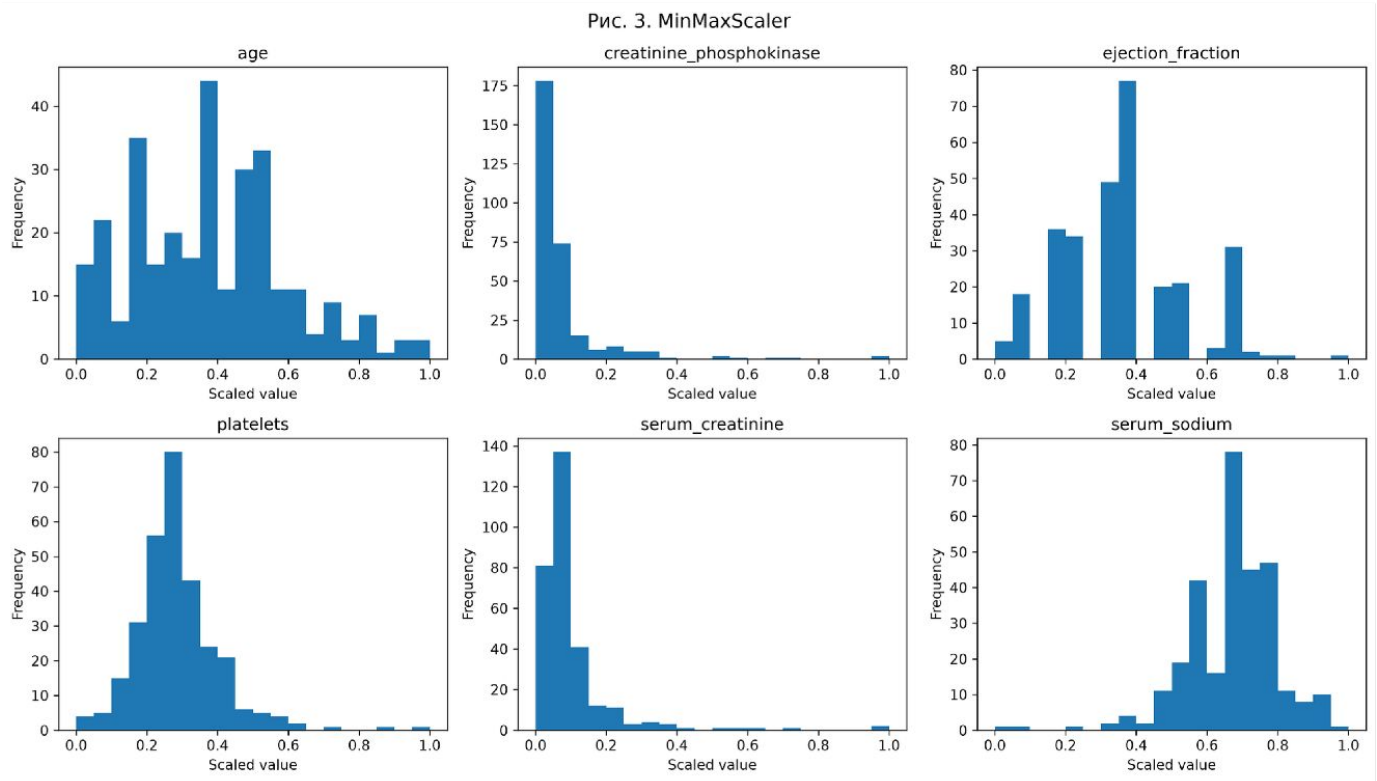


Рисунок 3. MinMaxScaler. **[Вопрос 3, Задание 2]**

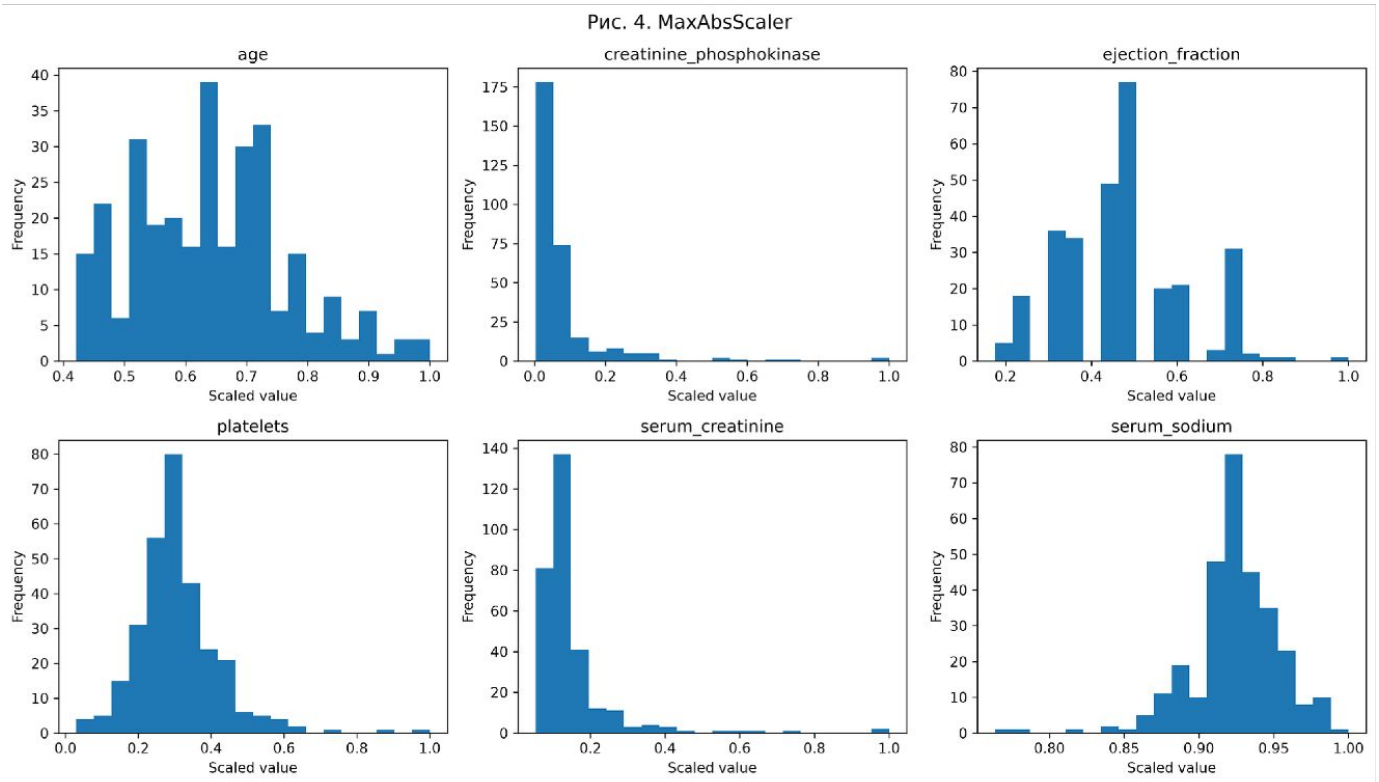


Рисунок 4. MaxAbsScaler. **[Вопрос 3, Задание 4]**

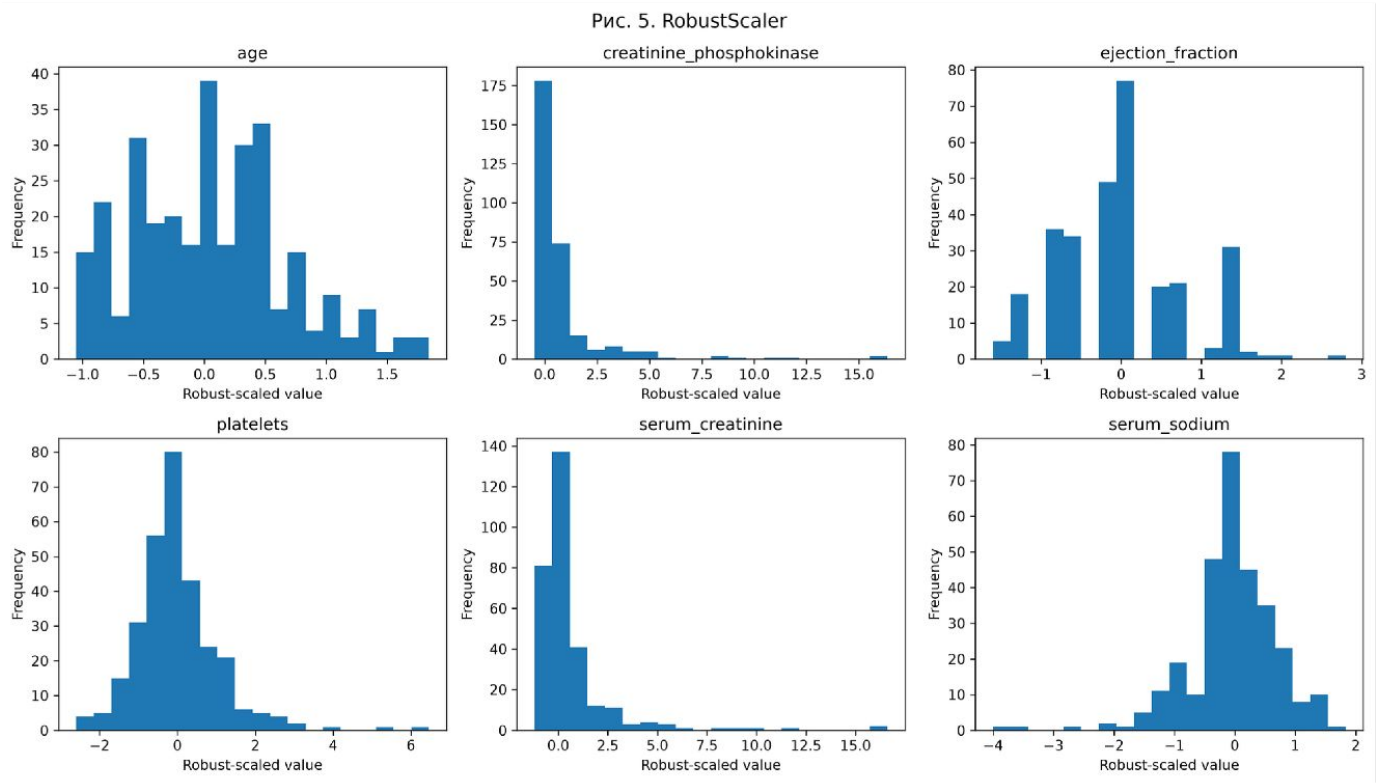


Рисунок 5. RobustScaler. **[Вопрос 3, Задание 4]**

Рис. 7. Собственное приведение к диапазону [-5, 10]

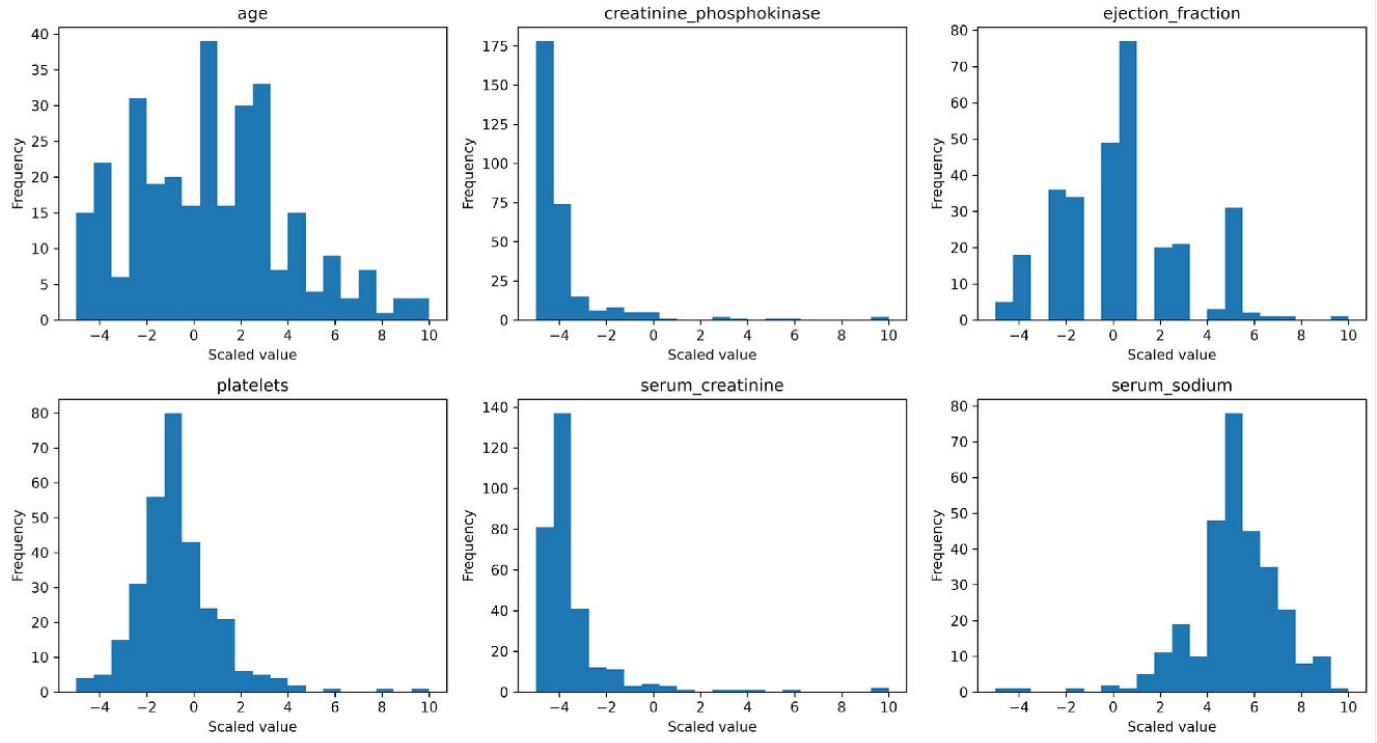


Рисунок 7. Масштабирование к [-5, 10]. **[Вопрос 3, Задание 5]**

Нелинейные преобразования

Квантильное (uniform, normal)

$$x' = \hat{F}(x), \quad x' = \Phi^{-1}(\hat{F}(x))$$

Yeo–Johnson, x ≥ 0

$$\frac{(x+1)^{\lambda} - 1}{\lambda}, \\ \ln(x+1) \text{ при } \lambda = 0$$

- Равномерный выход выравнивает гистограммы на [0, 1]; нормальный выход даёт колоколообразные гистограммы. **[Вопрос 4, Задания 2 и 5]**
- n_quantiles задаёт число опорных точек эмпирической функции распределения. Я проверил 10, 50, 100 и 299; значения больше объёма выборки ограничиваются 299. **[Вопрос 4, Задание 3]**
- Оценённые λ: 0.021, −0.163, 0.285, 0.491, −2.325, 7.01. **[Вопрос 4, Задание 6]**

Ограничение

Повторяющиеся значения, например многочисленные одинаковые записи platelets и creatinine_phosphokinase, образуют пики, которые не может разделить ни одно монотонное преобразование.

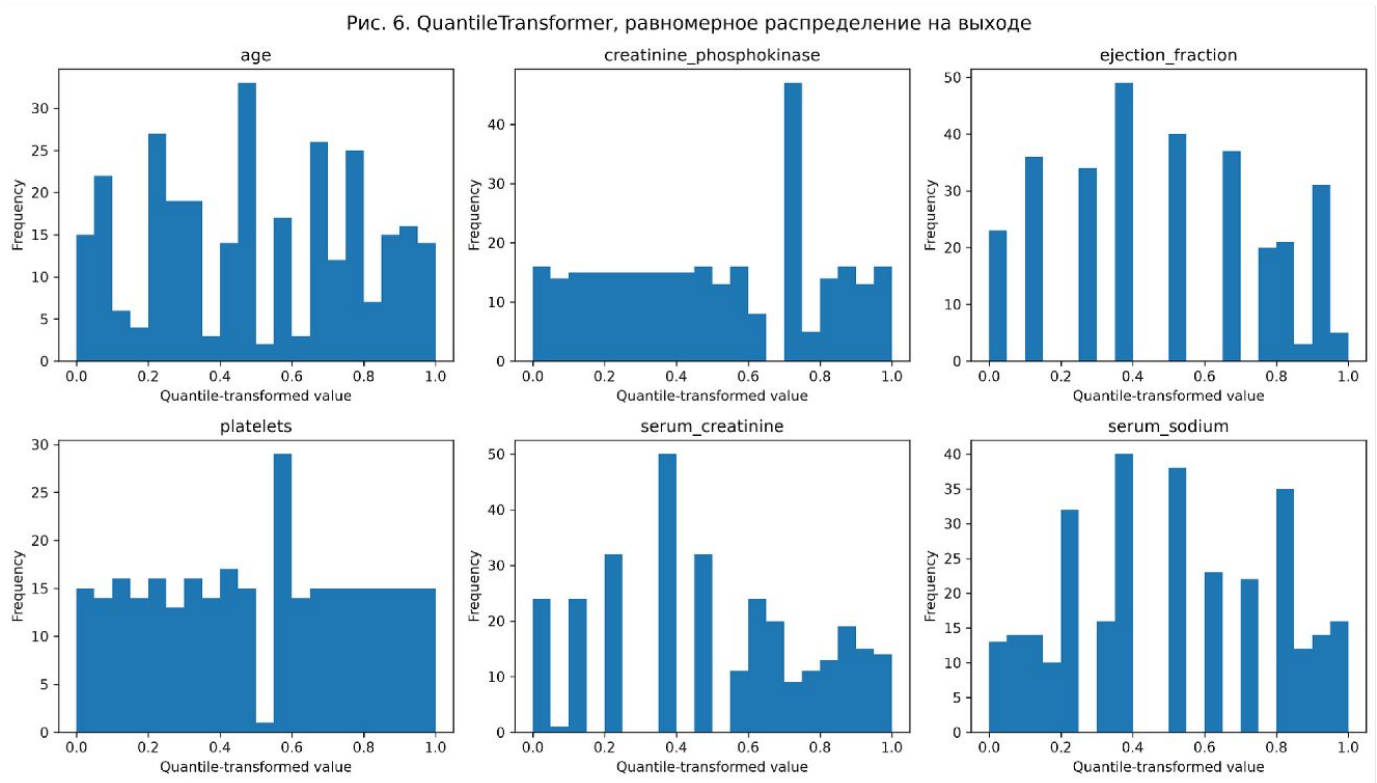


Рисунок 6. QuantileTransformer, равномерный выход. **[Вопрос 4, Задание 2]**

Рис. 8. QuantileTransformer, нормальное распределение на выходе

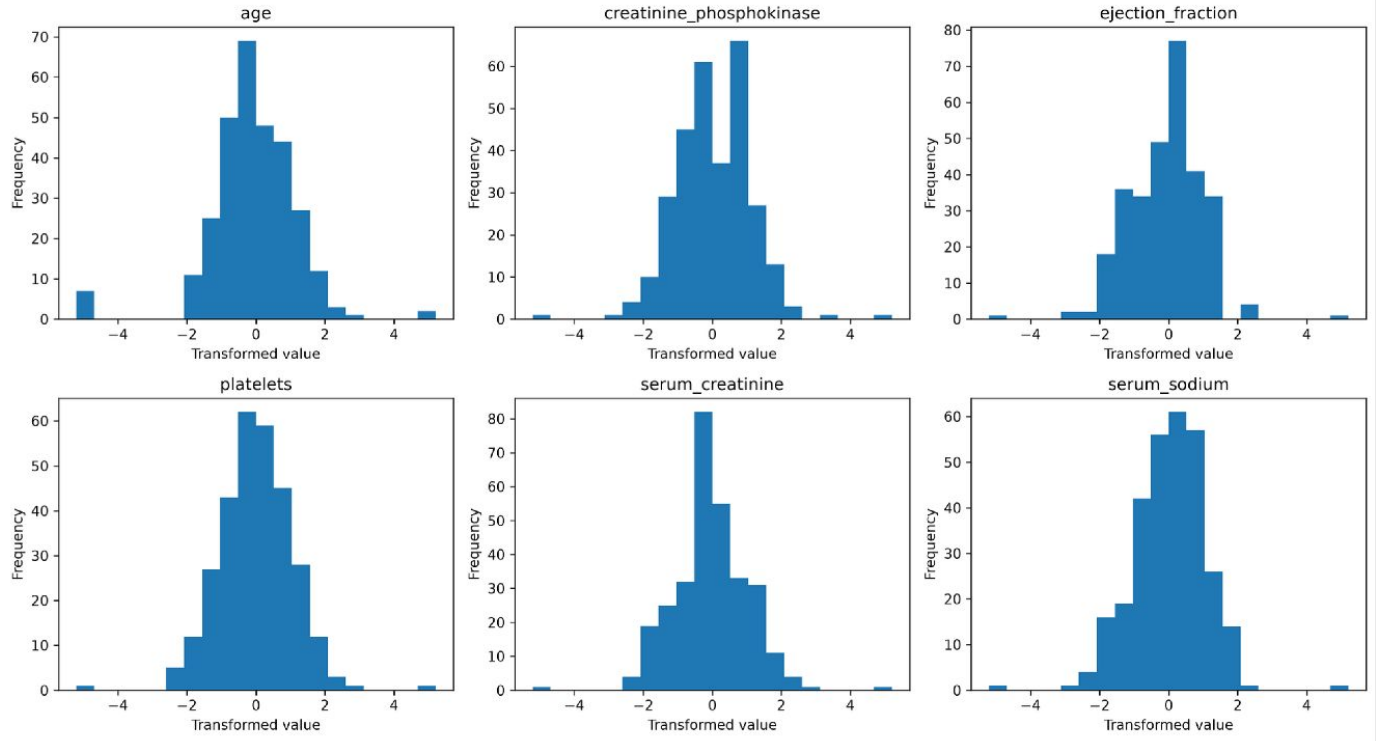


Рисунок 8. QuantileTransformer, нормальный выход. **[Вопрос 4, Задание 5]**

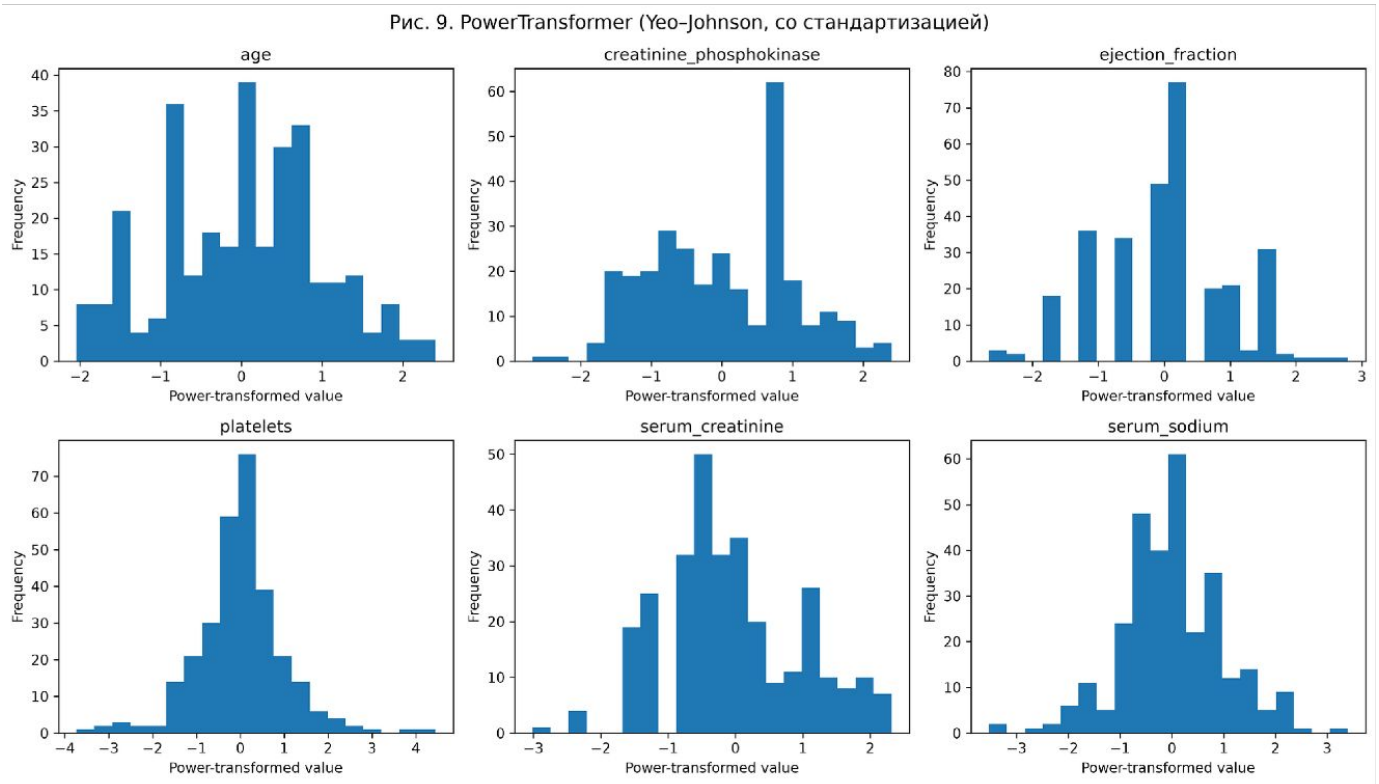


Рисунок 9. PowerTransformer (Yeo–Johnson, стандартизованный). **[Вопрос 4, Задание 6]**

Дискретизация признаков

KBinsDiscretizer применялся с отдельным числом интервалов для каждого признака, подобранным под его разброс. В таблице 2 приведены полученные квантильные границы интервалов. **[Вопрос 5, Задание 1]**

Признак	Интервалы	Границы
age	3	40, 55, 65, 95
creatinine_phosphokinase	4	23, 115, 250, 582, 7861
ejection_fraction	3	14, 35, 40, 80
platelets	10	25100, 153000, 196000, 221000, 237000, 262000, 265000, 286000, 321000, 377000, 850000
serum_creatinine	2	0.5, 1.1, 9.4
serum_sodium	4	113, 134, 137, 140, 148

Таблица 2 Квантильные границы интервалов по признакам. **[Вопрос 5, Задание 3]**

Квантильная стратегия стремится к равному числу наблюдений в каждом интервале. Когда много одинаковых значений попадает на границу, совпадения делают заполнение неравномерным, что заметно для platelets и serum_creatinine. **[Вопрос 5, Задание 2]**

Рис. 10. Дискретизация KBinsDiscretizer

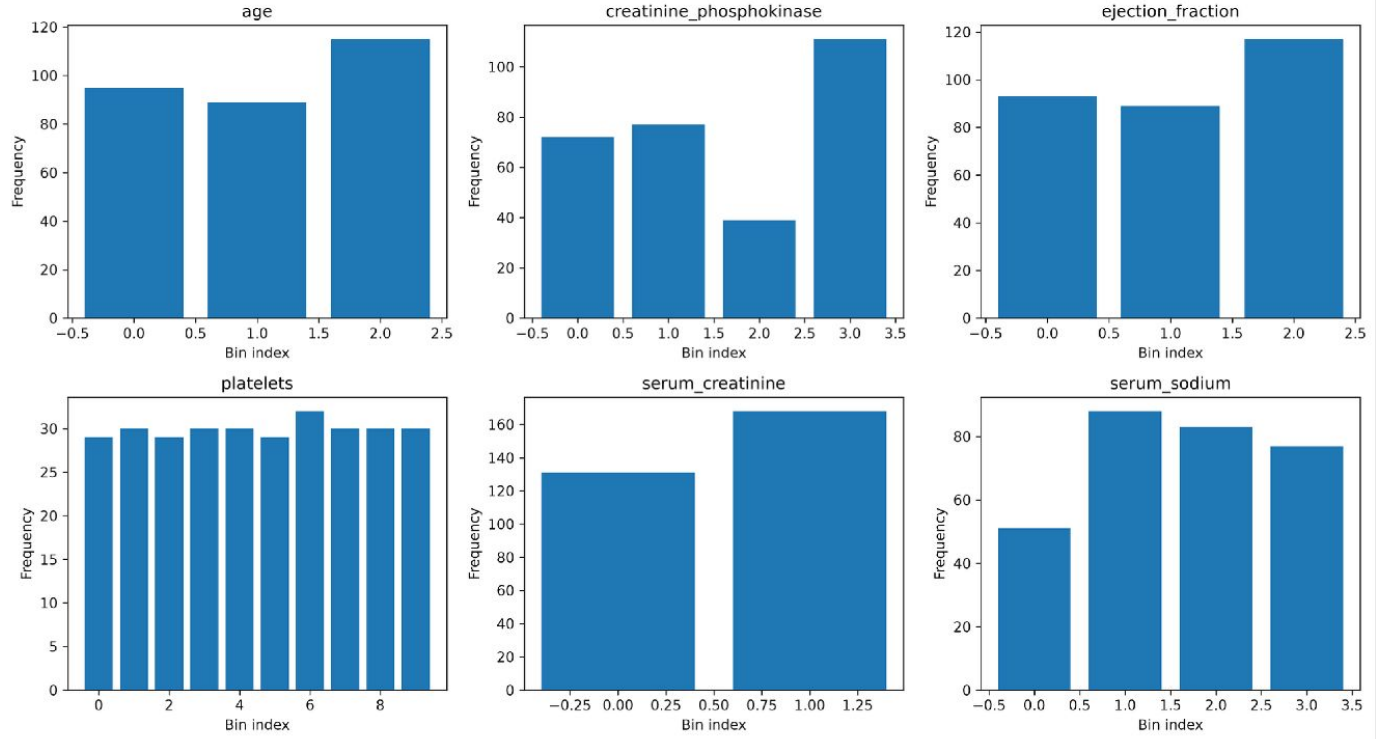


Рисунок 10. Данные после дискретизации KBinsDiscretizer. **[Вопрос 5, Задание 2]**

Трудности и их устранение

Вводящая в заблуждение первичная оценка

Средние после стандартизации не были равны 0 (age −0.17), а стандартное отклонение — 1 (0.95). Причина — обучение только на 150 строках при преобразовании 299; это подтверждено повторным обучением на всех данных, которое даёт ровно 0 и 1.

Неверная настройка параметров

По умолчанию KBinsDiscretizer возвращает разреженный one-hot результат, и при построении графика возникла ошибка "TypeError: sparse array length is ambiguous". Она устранена параметром encode="ordinal"; strategy явно задан как "quantile".

Несогласованная предобработка

Неиспользуемый закомментированный код ручной стандартизации создавал риск смешения соглашений ddof. Принято ddof = 0, как в scikit-learn.

---

n_quantiles больше объёма выборки

Выявлено по атрибуту n_quantiles_, который показал 299.

> В основном проблемы были не с самими методами, а с дефолтными настройками sklearn. Больше всего времени ушло на чтение документации и повторение статистики (дисперсия, IQR), так как я уже подзабыл эти темы

Заключение

По сути, линейное масштабирование (MinMax, Standard) просто сдвигает и сжимает значения, а нелинейные преобразования (Quantile, Power) реально меняют форму распределения. Ещё на практике убедился, что scaler надо обучать на тех же данных, на которых он потом применяется иначе средние значения не сойдутся (в моем случае получилось -0.17 вместо 0)

Линейные методы

Они меняют положение и масштаб, но сохраняют форму распределения; в MinMax и MaxAbs по-прежнему доминируют выбросы.

Асимметричные признаки

Для асимметричных признаков, таких как creatinine_phosphokinase, предпочтителен RobustScaler.

Нелинейные преобразования

Квантильное и степенное преобразования меняют форму распределений, что полезно для моделей, предполагающих нормальность.

Подвыборка для обучения

Масштабировщики нужно обучать на той же подвыборке, на которой они оцениваются; это главный урок для предотвращения утечки между обучающими и тестовыми данными.